

Projet d'EDP

Résolution numérique du problème de navigation de Zermelo dans un environnement aléatoire

Franck DEBA WANDJI Durel Valdes NZIALI TCHAMOU

26 Mars 2026

Table des matières

1	Introduction	2
1.1	Modélisation du problème	2
1.2	Spécificités du problème	2
1.3	Paramètres de référence	3
2	Objectifs du projet	3
3	Méthode des différences finies	4
3.1	Discrétisation du domaine	4
3.2	Schéma de Newton semi-lisse	4
3.3	Analyse du schéma	4
3.4	Cas A : solution exacte connue	5
3.5	Cas B : $f = 1$, solution inconnue	6
4	Approche par réseaux de neurones (PINNs)	7
4.1	Architecture du réseau	7
4.2	Trois formulations de la fonction de perte	7
4.3	Paramètres d'entraînement	8
4.4	Cas A : solution exacte connue	8
4.5	Cas B : $f = 1$, solution inconnue	9
5	Conclusion	10
6	Annexes	10
6.1	Solutions obtenues pour les différentes fonctions de perte	10

1 Introduction

Ce projet s'inscrit dans l'étude des équations d'Hamilton-Jacobi-Bellman-Isaacs (HJBI) apparaissant dans les problèmes de contrôle optimal et de contrôle robuste. Nous nous intéressons plus particulièrement à un problème de navigation stochastique, connu sous le nom de problème de Zermelo, où un bateau cherche à optimiser son temps de sortie d'un domaine soumis à un vent fort, en présence d'incertitude sur la perturbation stochastique [2].

1.1 Modélisation du problème

La dynamique contrôlée du bateau est décrite par l'équation différentielle stochastique suivante :

$$dX_t = b(X_t, \alpha_t) dt + \sigma dW_t, \quad X_0 = x \in \Omega \quad (1)$$

où α_t représente la stratégie de contrôle (direction du bateau), b est la vitesse résultante (somme de la vitesse du vent et de la vitesse propre du bateau), et σ est une matrice de diffusion modélisant le bruit.

La fonction valeur associée au problème est définie par :

$$u(x) = \inf_{\alpha} \sup_{Q \in \mathcal{M}} \mathbb{E}^Q \left[\int_0^{\tau} f(X_t) dt + g(X_{\tau}) \right] \quad (2)$$

où $\mathcal{M}$ représente un ensemble de mesures de probabilité absolument continues par rapport à la mesure de référence, encodant l'incertitude sur le modèle de bruit, et τ est le temps de sortie du domaine.

Par des arguments de programmation dynamique, on montre que u est l'unique solution de viscosité d'une équation HJBI de la forme :

$$F(x, u, \nabla u, D^2 u) = 0 \quad \text{dans } \Omega \quad (3)$$

avec des conditions de Dirichlet sur la frontière $\partial\Omega$.

1.2 Spécificités du problème

Le domaine de calcul est un anneau :

$$\Omega = \{(x, y) \in \mathbb{R}^2 : r^2 < x^2 + y^2 < R^2\} \quad (4)$$

Le champ de vent est supposé principalement horizontal, avec une intensité variant radialement :

$$v_c(x, y) := 1 - a \sin \left(\pi \frac{x^2 + y^2 - r^2}{R^2 - r^2} \right) \quad (5)$$

La dynamique contrôlée s'écrit alors :

$$b((x, y), \alpha) := \begin{pmatrix} v_c(x, y) + v_s \cos \alpha \\ v_s \sin \alpha \end{pmatrix} \quad (6)$$

où $\alpha \in [0, 2\pi]$ est l'angle de direction du bateau.

L'équation HJBI résultante est :

$$-\frac{1}{2} (\sigma_x^2 u_{xx} + \sigma_y^2 u_{yy}) - v_c(x, y) u_x + v_s \|\nabla u\|_2 - \kappa \|\nabla u\|_1 - f(x, y) = 0, \quad x \in \Omega \quad (7)$$

Les conditions aux limites sont :

$$u = 0 \text{ sur } \partial B_r, \quad u = 1 \text{ sur } \partial B_R \quad (8)$$

Le terme f est le coût de fonctionnement : $f \equiv 1$ correspond à la minimisation du temps de sortie.

1.3 Paramètres de référence

Les simulations sont conduites avec les paramètres suivants, conformément à [2] :

$$r = 0.5, \quad R = \sqrt{2}, \quad \kappa = 0.1, \quad v_s = 0.5, \quad a = 0.2, \quad \sigma_x = 0.5, \quad \sigma_y = 0.2 \quad (9)$$




FIGURE 1 – Schéma du domaine annulaire et illustration du problème de navigation

2 Objectifs du projet

L'objectif de ce travail est de comparer deux approches numériques pour la résolution de ce problème :

1. Une méthode de différences finies avec schéma de Newton semi-lisse, permettant d'obtenir une solution de référence.
2. Une approche par réseaux de neurones (Physics-Informed Neural Networks - PINNs) dans trois variantes : loss L^2 standard, loss Sobolev $H^{3/2}$, et loss avec itération de politique (lisse).

L'analyse portera sur la précision, la vitesse de convergence et la robustesse des deux approches.

3 Méthode des différences finies

3.1 Discrétisation du domaine

Pour résoudre numériquement l'équation (7), nous commençons par discrétiser le domaine. L'anneau Ω est plongé dans un carré englobant $K := [-2, 2]^2$. On introduit un maillage cartésien régulier :

$$x_i = X_{\min} + ih_x, \quad 1 \leq i \leq M_x, \quad y_j = Y_{\min} + jh_y, \quad 1 \leq j \leq M_y \quad (10)$$

avec $h_x = \frac{X_{\max} - X_{\min}}{M_x + 1}$, $h_y = \frac{Y_{\max} - Y_{\min}}{M_y + 1}$. Pour simplifier, nous prenons $M_x = M_y = M$.

L'inconnue discrète est notée $U = (u_{i,j})_{1 \leq i,j \leq M}$, où $u_{i,j} \approx u(x_i, y_j)$. On définit le rayon $r_{i,j} := \sqrt{x_i^2 + y_j^2}$ et les ensembles suivants :

- $\Omega_{\text{int}} := \{(x_i, y_j) \in \Omega\}$: nœuds intérieurs
- $\Gamma_r := \{(x_i, y_j) \in K, r_{i,j} \leq r\}$: nœuds du bord intérieur
- $\Gamma_R := \{(x_i, y_j) \in K, r_{i,j} \geq R\}$: nœuds du bord extérieur

3.2 Schéma de Newton semi-lisse

À chaque itération n , connaissant U^n , on résout le système linéaire suivant pour U^{n+1} :

$$\begin{aligned} & -\frac{1}{2}\sigma_x^2(D_x^2 U^{n+1})_{i,j} - \frac{1}{2}\sigma_y^2(D_y^2 U^{n+1})_{i,j} - v_c(x_i, y_j)(D_x^1 U^{n+1})_{i,j} \\ & + v_s \langle \alpha(U^n)_{i,j}, (D^1 U^{n+1})_{i,j} \rangle - \kappa \langle \beta(U^n)_{i,j}, (D^1 U^{n+1})_{i,j} \rangle - f(x_i, y_j) = 0, \quad (i, j) \in \Omega_{\text{int}} \end{aligned} \quad (11)$$

où l'on définit :

$$\alpha(U)_{i,j} := \frac{(D^1 U)_{i,j}}{\|(D^1 U)_{i,j}\|_2}, \quad \beta(U)_{i,j} := (\text{sign}(D_x^1 U)_{i,j}, \text{sign}(D_y^1 U)_{i,j}) \quad (12)$$

Cette formulation s'appuie sur les représentations duales des normes :

$$\|\nabla u\|_2 = \sup_{\|\alpha\|_2=1} \langle \alpha, \nabla u \rangle, \quad \|\nabla u\|_1 = \sup_{\|\beta\|_\infty=1} \langle \beta, \nabla u \rangle \quad (13)$$

Les opérateurs de différences finies centrées sont définis par :

$$(D_x^2 U)_{i,j} = \frac{U_{i+1,j} - 2U_{i,j} + U_{i-1,j}}{h_x^2}, \quad (D_y^2 U)_{i,j} = \frac{U_{i,j+1} - 2U_{i,j} + U_{i,j-1}}{h_y^2} \quad (14)$$

$$(D_x^1 U)_{i,j} = \frac{U_{i+1,j} - U_{i-1,j}}{2h_x}, \quad (D_y^1 U)_{i,j} = \frac{U_{i,j+1} - U_{i,j-1}}{2h_y} \quad (15)$$

Les conditions aux limites sont imposées fortement :

$$U_{i,j} = 0 \text{ sur } \Gamma_r, \quad U_{i,j} = 1 \text{ sur } \Gamma_R \quad (16)$$

3.3 Analyse du schéma

Bien-posé. Le schéma itératif est bien posé sous réserve que la matrice du système linéaire soit à diagonale dominante. Cette condition est satisfaite pour des pas de maillage h_x, h_y suffisamment petits, car les coefficients α et β sont bornés ($\|\alpha\|_2 \leq 1$, $\|\beta\|_\infty \leq 1$).

Lien avec Newton semi-lisse. Le schéma correspond à une méthode de Newton semi-lisse appliquée à l'opérateur non-linéaire F défini par (7). Les termes non-différentiables $\|\nabla u\|_2$ et $\|\nabla u\|_1$ sont remplacés par leurs sous-gradients, donnant lieu à une linéarisation locale.

3.4 Cas A : solution exacte connue

Pour valider la méthode, on construit une solution exacte :

$$u_{ex}(x, y) = \sin\left(\frac{\pi}{2} \cdot \frac{x^2 + y^2 - r^2}{R^2 - r^2}\right) \quad (17)$$

Cette fonction vérifie bien $u_{ex} = 0$ sur ∂B_r et $u_{ex} = 1$ sur ∂B_R . Le second membre f est alors déterminé en reportant u_{ex} dans l'équation (7).




FIGURE 2 – Solution exacte (gauche) et erreur absolue (droite) obtenues par différences finies pour $M = 80$

L'analyse de convergence montre un ordre numérique proche de 1, inférieur à l'ordre théorique de 2 attendu pour un schéma centré. Cette dégradation s'explique par la géométrie cartésienne utilisée sur une frontière circulaire, qui introduit des erreurs de raccord au bord. Une discrétisation en coordonnées polaires permettrait d'atteindre l'ordre optimal.

M	erreur	ordre α	temps CPU (s)
10	0.424347	NAN	0.028955
20	0.106676	2.135322	0.080288
40	0.060535	0.846822	0.260748
80	0.031743	0.948138	0.685356
160	0.027692	0.198708	3.765474
360	0.026303	0.074620	17.749870
640	0.025430	0.048789	67.458325

TABLE 1 – Test de convergence (cas A : solution exacte connue)

3.5 Cas B : $f = 1$, solution inconnue

On considère maintenant le cas $f \equiv 1$, pour lequel la solution exacte n'est pas connue analytiquement.




FIGURE 3 – Solution numérique obtenue par différences finies pour $f = 1$

Pour évaluer la convergence sans solution exacte, on utilise l'erreur estimée par différence entre solutions successives $\|U_M - U_{M_{\text{prev}}}\|_\infty$, où $U_{M_{\text{prev}}}$ est interpolée bilinéairement sur le maillage fin. Cette interpolation est définie par :

$$u(x, y) = (1 - s)(1 - t)U_{i,j} + (1 - s)tU_{i,j+1} + s(1 - t)U_{i+1,j} + stU_{i+1,j+1} \quad (18)$$

avec $s = (x - x_i)/h$, $t = (y - y_j)/h$. Les résultats confirment un ordre de convergence proche de 1.

M	erreur	ordre α	temps CPU (s)
10	∞	-	0.011835
20	4.487353	-	0.031463
40	2.456894	0.900329	0.105593
80	1.260411	0.980294	0.466811
160	0.996527	0.341969	2.453844
320	0.549916	0.861564	9.618559
640	0.308724	0.834770	56.115489

TABLE 2 – Test de convergence (cas B : $f = 1$, solution exacte inconnue)

4 Approche par réseaux de neurones (PINNs)

4.1 Architecture du réseau

La solution u est approchée par un réseau de neurones fully-connected $\Phi(\cdot; \theta)$ avec activation $\varrho(y) = \tanh(y)$, de profondeur $L = 3$ et de largeur cachée $H = 50$. La fonction d'activation $\tanh$ assure la régularité C^∞ nécessaire au calcul des dérivées.

4.2 Trois formulations de la fonction de perte

Variante 1 : Loss L^2 standard. La fonction de perte mesure le résidu de l'EDP et le non-respect des conditions aux limites en norme L^2 :

$$\mathcal{L}_{L^2}(\theta) = \frac{|\Omega|}{N_0} \sum_{x_i \in \Omega_d} |F(x_i, u_\theta, \nabla u_\theta)|^2 + \sum_{l \in \{r, R\}} \frac{|\partial B_l|}{N_b} \sum_{i=1}^{N_b} |(u_\theta - g_l) \circ \Phi_l(\theta_i)|^2 \quad (19)$$

où $|\Omega| = \pi(R^2 - r^2)$, $|\partial B_l| = 2\pi l$, et $\Phi_l(\theta) = (l \cos \theta, l \sin \theta)$.

Variante 2 : Loss Sobolev $H^{3/2}$. Pour améliorer la convergence des dérivées, on incorpore une norme fractionnaire sur le bord :

$$\begin{aligned} J_k(u) = & \|L_k u - f_k\|_{L^2(\Omega)}^2 + \sum_{l \in \{r, R\}} \left[\|u - g\|_{L^2(\partial B_l)}^2 + \gamma \int_{-\pi}^{\pi} |D_\theta(u \circ \Phi_l)|^2 d\theta \right. \\ & \left. + \gamma \int_{(-\pi, \pi)^2} \frac{|D_\theta(u \circ \Phi_l)(\theta_1) - D_\theta(u \circ \Phi_l)(\theta_2)|^2}{|\theta_1 - \theta_2|^2} d\theta_1 d\theta_2 \right] \end{aligned} \quad (20)$$

avec $\gamma = 0.1$.

Variante 3 : Loss avec schéma de Newton semi-lisse. On exploite la structure de l'opérateur en linéarisant les termes non-différentiables comme dans l'approche par les différences finies :

$$v_s \|\nabla u\|_2 = v_s \sup_{\|\alpha\|_2 \leq 1} \langle \alpha, \nabla u \rangle, \quad \kappa \|\nabla u\|_1 = \kappa \sup_{\|\beta\|_\infty \leq 1} \langle \beta, \nabla u \rangle \quad (21)$$

Les contrôles optimaux sont $\alpha^*(x) = \nabla u(x) / \|\nabla u(x)\|_2$ et $\beta^*(x) = \text{sign}(\nabla u(x))$. À chaque itération k , on les fixe pour obtenir un problème linéaire :

$$L_k u^{k+1} := -\frac{1}{2} (\sigma_x^2 \partial_{xx} + \sigma_y^2 \partial_{yy}) u^{k+1} - v_c \partial_x u^{k+1} + v_s \langle \alpha^k, \nabla u^{k+1} \rangle - \kappa \langle \beta^k, \nabla u^{k+1} \rangle = f \quad (22)$$

4.3 Paramètres d'entraînement

L'optimisation est réalisée avec l'algorithme Adam, avec un taux d'apprentissage initial de 10^{-3} diminué d'un facteur 0.5 toutes les 2000 itérations SGD. La taille des mini-lots est fixée à $B = 25$ points, tirés aléatoirement à chaque itération. Un critère d'arrêt supplémentaire stoppe l'entraînement si la perte ne diminue pas après 500 itérations successives.

4.4 Cas A : solution exacte connue

Pour $v_s = 0.6$, les métriques d'évaluation sont l'erreur relative et le q -facteur :

$$\text{Err}_k = \frac{\|u^k - u^*\|_{2,\Omega,\text{val}}}{\|u^*\|_{2,\Omega,\text{val}}}, \quad q_k = \frac{\|u^k - u^*\|_{2,\Omega,\text{val}}}{\|u^{k-1} - u^*\|_{2,\Omega,\text{val}}} \quad (23)$$

évalués sur $N_{\text{val}} = 2000$ points indépendants.




FIGURE 4 – Impact de η_0 sur les performances de l'algorithme, de gauche à droite : erreurs relatives, q -facteurs et temps d'exécution total pour toutes les itérations de politique

Nous présentons ici (figure 4) les résultats de convergence numérique pour différents hyperparamètres η_k . On constate que l'erreur relative décroît et le facteur q tend à converger vers 1 avec des temps de calcul de plus en plus faibles. Cette observation, qui n'est pas identique à celle de l'article de référence, n'est pas surprenante sachant que nous avons introduit une condition d'arrêt supplémentaire lorsque, au bout de 500 itérations de la descente de gradient, on n'observe aucune réduction de la fonction de perte. Ce choix a été fait pour pouvoir avoir des temps de calcul raisonnables sur un CPU de faible puissance. La restriction peut aisément être retirée pour des calculs sur un GPU permettant de retrouver les résultats de l'article.

La comparaison des solutions obtenues en considérant chacune des trois fonctions de perte présentées plus haut montre clairement qu'avec les fonctions de perte L^2 et J (figures 7, 8), on a du mal à bien approcher la solution sur les bords du domaine avec une approche directe. En revanche, la linéarisation avec itération de stratégies optimales à la Newton semi-lisse donne une meilleure approximation sur l'ensemble du domaine et en particulier sur les bords (figure 9).

4.5 Cas B : $f = 1$, solution inconnue

Deux scénarios sont étudiés selon la vitesse relative du bateau par rapport au vent. Nous utilisons ici la version lisse de la norme avec $\eta_0 = 40$ et $\eta_k = 4^{-k}$.




FIGURE 5 – Solution numérique PINNs pour $v_s = 0.5$

Scénario $v_s = 0.5$ (bateau plus lent que le vent). Sur la partie gauche de l’anneau, les faibles valeurs de u indiquent que le vent pousse le bateau vers le bord intérieur. Sur la partie droite proche du bord intérieur, le bateau navigue à contre-courant ; loin de ce bord, il ne peut plus atteindre ∂B_r et suit le vent vers le bord extérieur.




FIGURE 6 – Solution numérique PINNs pour $v_s = 1.2$

Scénario $v_s = 1.2$ (bateau plus rapide que le vent). Le bateau peut généralement atteindre le bord intérieur. Exception faite de la région proche du bord extérieur sur la droite, où le temps d’atteinte du bord intérieur dépasse 1 ; le bateau choisit alors de sortir directement par ∂B_R .

5 Conclusion

La méthode des différences finies avec schéma de Newton semi-lisse converge en 5 à 7 itérations et exhibe un ordre numérique proche de 1, avec une erreur $L^\infty < 0.03$ pour un maillage 80×80 . Cette méthode fournit une solution de référence robuste, mais son coût $O(M^3)$ la rend inadaptée aux problèmes de grande dimension.


L’approche par les réseaux de neurones, avec la loss L^2 standard, offre une grande flexibilité mais ne garantit pas la convergence des dérivées. L’ajout de la norme fractionnaire $H^{3/2}$ améliore significativement la précision en norme H^2 , confirmant l’analyse théorique de [2]. La loss avec itération de politique (lisse) permet une convergence q-superlinéaire dans $H^2(\Omega)$, avec un compromis optimal pour $\eta_0 = 40$ et $\eta_k = 4^{-k}$. La précision des solutions du réseau de neurones s’améliore lorsque l’on fait le choix d’approcher les dérivées de l’EDP par différences finies plutôt que d’utiliser le gradient automatique de PyTorch. Par ailleurs, la précision numérique est meilleure que celle du schéma de différences finies. La contrepartie de ce gain en précision est un coût computationnel bien plus important. Là où avec un schéma de différences finies on obtient une solution de précision 0.03 en moins d’un dixième de seconde, on obtient une solution de précision 0.02 avec un temps CPU de l’ordre de 100 secondes. Toutefois, on n’est plus soumis au fléau de la dimensionnalité qui survient très tôt avec la méthode classique.

Références

- [1] Esteve-Yagüe, C., Tsai, R., Massucco, A. *Finite-difference least square methods for solving Hamilton-Jacobi equations using neural networks*. Journal of Computational Physics, 524 :113721, 2025.
- [2] Ito, K., Reisinger, C., Zhang, Y. *A neural network-based policy iteration algorithm with global H^2 -superlinear convergence for stochastic games on domains*. Foundations of Computational Mathematics, 21(2) :331–374, 2021.

6 Annexes

6.1 Solutions obtenues pour les différentes fonctions de perte






FIGURE 7 – Solution numérique obtenue par différences finies pour l’approche PINNs avec solution exacte : fonction de perte L^2




FIGURE 8 – Solution numérique obtenue par différences finies pour l’approche PINNs avec solution exacte : fonction de perte J non linéarisée




FIGURE 9 – Solution numérique obtenue par différences finies pour l’approche PINNs avec solution exacte : fonction de perte J linéarisée